基于 Transformer 的多阶段运动模糊图像修复网络

朱凯[1]，李理[1,2]，张彤[1]，江晟[1]，别一鸣[3]

（1. 长春理工大学物理学院，吉林 长春 130022；2. 长春理工大学电子信息工程学院，吉林 长春 130022；
3. 吉林大学交通学院，吉林 长春 130022）

摘　要： 运动模糊是导致图像退化的常见原因，其限制了图像的可读性和后续处理效果。针对卷积网络感受野有限以及常规多阶段网络中信息丢失的问题，提出一种基于 Transformer 的多阶段去模糊网络。网络采用多阶段编码器-解码器结构，在单个阶段内和多个阶段间采用跳跃连接来增强信息的传递。首先，高效 Transformer 模块采用通道注意力和深度卷积来处理图像的全局和局部信息；其次，多分支结构的前馈传播网络通过引入多个并行的分支，实现了不同尺度和不同层次的特征提取和融合；最后，通过多阶段的残差处理实现更优的图像恢复结果。实验结果显示，在 GoPro 数据集上该网络的峰值信噪比（PSNR）达到 32.23 dB，结构相似性指数（SSIM）达到 0.955，在 HIDE 数据集上 PSNR 和 SSIM 分别达到 30.15 dB 和 0.930，优于 DeepDeblur、DeblurGAN-V2 等模型。

关键词： 深度学习；Transformer 模型；注意力机制；图像修复；多尺度网络

中图分类号： TP391　　**文献标志码：** A　　**DOI：** 10.19678/j.issn.1000-3428.0068246

Multi-Stage Motion Blur Image Restoration Network Based on Transformer

ZHU Kai[1], LI Li[1,2], ZHANG Tong[1], JIANG Sheng[1], BIE Yiming[3]

(1. School of Physics, Changchun University of Science and Technology, Changchun 130022, Jilin, China;
2. School of Electronical and Information Engineering, Changchun University of Science and Technology, Changchun 130022, Jilin, China;
3. School of Transportation, Jilin University, Changchun 130022, Jilin, China)

【Abstract】 Motion blur is a common cause of image degradation that limits image readability and subsequent processing. A multi-stage deblurring network based on the Transformer is proposed to address the limited receptive field of convolutional networks and information loss in conventional multi-stage networks. The network adopts a multi-stage encoder-decoder structure with skip connections within and between stages to enhance information propagation. First, an efficient Transformer module is used to process the global and local information of the image using channel attention and depthwise convolution. Second, a multi-branch feedforward network with multiple parallel branches is introduced to extract and fuse features at different scales and levels. Finally, superior image restoration results are achieved through multi-stage residual learning. Experimental results show that the proposed method achieves a Peak Signal-to-Noise Ratio (PSNR) of 32.23 dB and Structural Similarity Index Measure (SSIM) of 0.955 on the GoPro dataset, and a PSNR of 30.15 dB and SSIM of 0.930 on the HIDE dataset, demonstrating a performance superior to DeepDeblur, DeblurGAN-V2, and other models.

【Key words】 deep learning; Transformer model; attention mechanism; image restoration; multi-scale network

0　引言

运动模糊是导致图像退化的一种常见原因，在拍摄时，由于相机或者物体本身的运动，图像中的物体位置会发生变化，导致图像产生运动模糊现象，这会使得图像丢失细节信息，导致图像质量下降从而影响图像的有效性和可读性，同时也限制了图像在后续处理和分析中的应用。因此，如何去除运动模糊成为图像修复领域的热门研究方向。

针对图像运动模糊问题，许多解决方法相继被提出。传统的去模糊方法有基于维纳滤波器[1]的方法、基于 Lucy-Richardson 算法的反卷积方法[2-3]和基于超拉普拉斯算子的去模糊先验[4]等。这些方法通常需要事先对待处理图像和模糊核进行一定的假设和限定，同时还需要多次手动设置参数，因此，它们具有一定的局限性，并且难以处理一些具有复杂退化形式的图像。

近年来，随着深度学习技术的不断发展，基于深度学习的去模糊方法取得了巨大的进步。一些早期的工作主要利用卷积神经网络（CNN）来估计图像中的模糊核并利用估计结果进行图像去模糊[5-7]，这种方法可以有效地处理一些简单的退化问题，但在

收稿日期： 2023-08-17　　**修回日期：** 2023-11-22

基金项目： 吉林省科技发展计划重点研发项目（20210203214SF）。

通信作者 E-mail： kylechuzk@gmail.com

计算机工程 www.ecice06.com

处理具有复杂退化形式的图像时表现不佳。

随着硬件技术的进步，许多基于深度学习的端到端去模糊方法逐渐被提出。文献[8]使用生成对抗网络来解决图像去模糊问题；文献[9]提出了一种基于堆叠策略的端到端 CNN 分层去模糊网络；文献[10]提出了一种由空间自适应残差学习模块组成的 CNN 去模糊结构。基于 CNN 的去模糊方法一直以来都是图像处理的主力，但是由于 CNN 结构在参数共享上的局限性以及有限感受野的原因，使其在处理复杂的细节信息和全局特征时比较受限。为了克服这些问题，研究人员提出了一些有效的改进方法：以文献[11-12]提出的 DeepDeblur 为代表的多阶段多尺度卷积结构方法，通过在不同尺度下进行卷积操作，获得多层次的特征进而更好地捕捉目标物体的丰富细节；以文献[13]提出的参数选择共享和嵌套跳跃连接模型为代表的跨尺度连接和上下文信息融合方法，通过引入 U 型网络结构、空洞卷积等技术，加强跨尺度信息交互和全局上下文信息的利用。

CNN 模型通过结构来弥补感受野受限的不足，与之不同，文献[14]基于 Transformer[15] 结构提出 ViT(Vision in Transformer)模型，通过注意力机制来捕捉图像中的全局信息，相比于 CNN 结构有着更大的感受野，并且注意力机制允许每个位置都可以与其他位置进行交互并动态计算关注度，从而使模型更具灵活性和适应性，因此，其能更好地处理复杂的图像结构和细节信息。

由于 ViT 的巨大成功，通过视觉 Transformer 进行图像处理逐渐成为研究热点。文献[16]提出了一种基于 Swin Transformer[17] 的 U 型 Transformer 图像恢复模型，通过 Swin Transformer 的高效特征提取能力获得良好的图像恢复效果。文献[18]同样提出了一种基于高效 Transformer 的 U 形高分辨率图像恢复模型。文献[19]基于多尺度体系结构提出了一种将 CNN 和 Transformer 相结合的新型混合图像恢复结构，这使得模型可以更有效地处理不同范围的图像模糊。文献[20]将 Transformer 应用于频域，通过元素乘积运算来估计尺度上的点积注意力而不是在空间域中进行矩阵乘法，进而获得高质量的图像去模糊效果。文献[21]提出了应用于空间域与频域的双域注意力机制。然而，目前基于 Transformer 的图像恢复模型大多采用单一阶段的编码器-解码器结构，与此同时，基于多阶段编码器-解码器结构的研究还相对较少。更为重要的是，现有的多阶段结构在经过多次上采样和下采样操作后，存在多个子阶段之间信息传递不畅、信息丢失的问题。

针对以上问题，本文从加强阶段间联系以及增强单个模块的特征提取能力的角度来设计网络模型，提出一种基于 Transformer 和 CNN 的多阶段图像去模糊网络，该网络能较好地处理运动模糊图像。本文的主要贡献如下：

1)本文模型结合了 Transformer 和 CNN 对全局特征和局部特征提取的优势，并且在整体结构上采用了多阶段的编码器-解码器结构，在单个子阶段内和多个阶段间通过跳跃连接进一步加强信息传递以减少信息损失，进一步提高模型的性能和鲁棒性。

2)设计一种增强通道注意力模块，引入的 SE(Squeeze-and-Excitation)模块能够进一步增强有用特征的表示并抑制无用信息，使得模型对图像特征的提取能力进一步加强，进而提高模型的去模糊能力。

3)为了更好地保留与传递注意力模块提取到的特征信息，提出一种结合门控机制的多分支高效前馈传播网络，通过门控机制来确定哪些特征应该被保留以用于图像恢复，从而提升计算效率。

1 相关工作

1.1 去模糊方法

对于单图像运动模糊问题，早期的去模糊方法[1-4]的目标是找到有效的图像先验或者模糊核，这些方法大多基于模糊模型：

$$\boldsymbol{I}_b = \boldsymbol{I}_s \otimes \boldsymbol{K} + \boldsymbol{n} \tag{1}$$

式中：$\boldsymbol{I}_b$ 和 $\boldsymbol{I}_s$ 分别表示矢量化的模糊图像和潜在的清晰图像；$\boldsymbol{K}$ 和 $\boldsymbol{n}$ 分别表示模糊核的稀疏矩阵和加性噪声。

寻找模糊核并不容易，这是一个高度不适定性问题。随着深度学习技术的发展，研究者通过 CNN 来寻找模糊核并进行图像恢复。然而，简单的核卷积不能模拟几种具有挑战性的情况，并且为动态场景中的每个像素寻找空间变化的模糊核需要大量的内存和计算。文献[8]首次使用像素生成的方式直接将模糊图像转化为相应的锐化图像，这种方式不再需要估计模糊核，应用的范围更广，并且取得了更好的效果。

基于残差[22]的图像恢复方法是另一种不需要显式估计模糊核的方法，它通过模糊图像与学习到的残差图像相叠加来产生更高质量的图像，并且不存在生成方式中的模式崩溃等问题，相比于生成方式，其去模糊更加简单高效。基于残差的图像恢复方法模型如下：

计算机工程 www.ecice06.com

$$\boldsymbol{R}=\boldsymbol{I}+\boldsymbol{I}' \tag{2}$$

式中：$\boldsymbol{I}$ 和 $\boldsymbol{I}'$ 分别表示矢量化的模糊图像和残差图像；$\boldsymbol{R}$ 表示恢复的清晰图像。

基于残差的去模糊方法能够在保留模糊图像基本结构的同时，增强图像的细节和清晰度，这种图像恢复方式可以学习到更复杂的图像特征和模式，能够更好地恢复图像的细节，并且避免了传统方法中手动调整参数的问题。本文采用了基于残差的去模糊方法，并在此基础上引入多阶段处理结构以获得更好的结果。

1.2 多阶段处理结构

多阶段处理结构指将任务分解为多个步骤或阶段进行处理，每个阶段都专注于解决特定的子问题，并逐步推进整体任务的完成。每个阶段的输出可以作为下一个阶段的输入，从而实现信息的有序传递和处理。传统单阶段的处理结构可能无法充分利用图像中的信息和结构，而多阶段的处理结构可以通过子阶段在不同尺度上进行分析和处理，更好地捕捉图像的细节信息。

文献[11]首次将多阶段多尺度的处理结构引入图像去模糊任务中，取得了较好的去模糊效果。在此基础上，文献[23]引入权重共享的思想，提出了一种跨尺度的参数共享递归网络。文献[24]重新考虑了多尺度去模糊问题，使用多输入多输出编码器而不是传统的级联子网络。文献[25]提出了一种多尺度循环注意力网络，以兼顾模型的效率和去模糊效果。文献[26]提出一种基于多尺度的方法，以捕获多尺度下图像的低频和高频信息从而进行图像恢复。

阶段多尺度处理是一种有效的图像处理策略，通过分阶段和多尺度的处理来提高算法的性能和鲁棒性。多阶段的处理结构在计算机视觉任务中被广泛应用，并取得了良好的效果。

1.3 注意力机制

注意力机制应用于自然语言处理领域后取得了重大突破，而文献[14]基于注意力机制提出的 ViT 模型显示出注意力机制在计算机领域强大的应用前景。注意力机制可以从输入的大量数据中挑选出特征部分，其本质是通过权值来赋予输入数据某一关注程度。基于此，研究者探究出各种不同的注意力机制。通道注意力[27]通过对特征图的通道维度进行加权，从而调整不同通道的重要性。文献[17]提出的 Swin Transformer 基于窗口注意力，窗口注意力的创新性设计为注意力驱动的视觉任务带来了新的突破，为计算机视觉领域的研究提供了重要的启示和借鉴。文献[28]依据窗口注意力的思路提出了可拓展的滑动窗口注意力机制，将每个像素的注意力范围定位到其最近邻域，降低了内存消耗并提升了运行速度。

2 多阶段运动模糊图像修复网络

2.1 设计思路

为了得到更好的去模糊效果，本文在单阶段处理结构的基础上引入多阶段处理结构[11]。由于单阶段单尺度的处理结构可能存在无法充分利用图像中信息和结构的问题，因此本文将单阶段的处理执行 3 次，并在每个子阶段的处理过程中对不同尺度的图像进行分析，以更好地捕捉图像的细节信息。将第一阶段的输出作为第二阶段的输入，同时将第二阶段的输出作为第三阶段的输入，在这个过程中分辨率逐渐提高，以捕捉到更多的细节信息，进一步提高最后的恢复效果，其模型如下所示：

$$\boldsymbol{R}_i=\boldsymbol{I}_i+\boldsymbol{I}'_i \tag{3}$$

式中：$\boldsymbol{I}_i$ 和 $\boldsymbol{I}'_i$ 分别表示第 i 阶段矢量化的模糊图像和残差图像；$\boldsymbol{R}_i$ 表示第 i 阶段恢复的清晰图像。

随着阶段的增多以及网络的加深，为了避免梯度消失和模型训练困难的问题同时获得更好的效果，本文在单个阶段内和多个模块间引入跳跃连接[29]。图 1 展示了本文提出的模型结构简图，与 DeepDeblur[11]、PSS-NSC[30]、SRN[24] 模型相比，本文模型通过跳跃连接增加了模块间的连接。

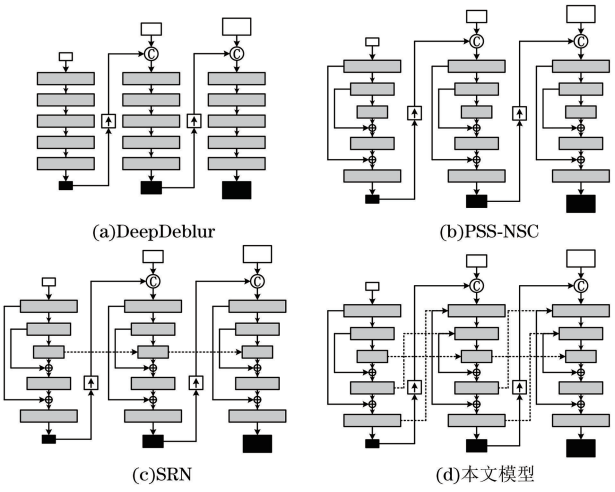


图 1 不同多阶段去模糊模型结构

Fig. 1 Different multi-stage deblurring model structures

为了减轻运算压力，在单个阶段内采用 3 级的编码器和解码器结构设计。在模块的设计上，考虑到内存与计算成本的原因，本文采用通道注意力而不是常规的空间注意力，因为通道注意力的计算量与输入特征图的通道数成正比，而空间注意力的计算量与输入特征图的空间尺寸成正比，如果采用空

计算机工程 www.ecice06.com

间注意力，当面对高分辨率图像时将消耗巨大的硬件资源。为了进一步增强通道注意力对通道特征的提取能力，本文在通道注意力的基础上嵌入 SE 模块[31]，其结构如图 2 所示。SE 模块通过学习特征图通道之间的权重关系，帮助模型更好地理解和利用输入数据的关键特征，进一步提升通道注意力对通道特征的提取能力。

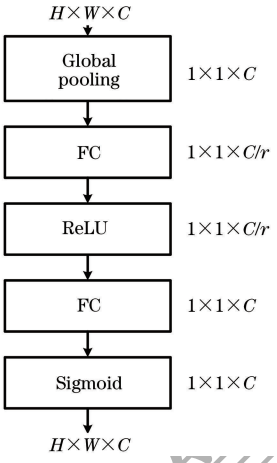


图 2 SE 模块结构

Fig. 2 SE module structure

为了在模块中更好地传输通过通道注意力捕捉到的通道特征，本文在单分支前馈传播网络的基础上，通过扩展分支结构的数量来实现更加多样的特征表示，且文献[32]也证明了多分支结构的优势。本文在传统单分支前馈传播网络的基础上，增加 2 个分支，即经过激活函数的卷积层和没有经过激活函数的卷积层，从而引入更加丰富的特征表示。将未经激活函数的卷积层与经过激活函数的卷积层相乘，引入线性与非线性结果，以提高模型的表达能力。单分支与多分支结构简图如图 3 所示。

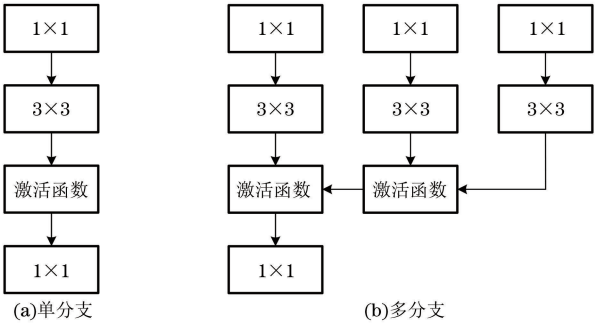


图 3 单分支与多分支结构

Fig. 3 Single-branch and multi-branch structure

2.2 整体结构

以往基于 Transformer 的图像恢复方法大多基于单个阶段的处理[16,18,33]，而本文提出的多阶段去模糊网络在总体架构上可分为 3 个处理不同尺度图像的编码器-解码器结构，每个子结构由具有相同结构的 3 级编码器-解码器组成。在每个子阶段的处理过程中都会生成一幅与子阶段退化图像相同大小的残差图，将残差图与退化图像直接相加得到子阶段的恢复图像，即 $\boldsymbol{R}_i=\boldsymbol{I}_i+\boldsymbol{I}'_i$。子阶段的恢复图像与下一阶段的输入图像在通道上进行拼接然后作为下一阶段的输入，通过高效 Transformer 模块进一步提取图像的全局和局部信息，从而提高模型的恢复效果。

图 4 详细展示了本文提出的模型总体结构。对于输入的退化图像 $\boldsymbol{I}$，首先通过下采样将图像分别缩小至原来尺寸的 1/4 与 1/2 得到 $\boldsymbol{I}_1$ 和 $\boldsymbol{I}_2$，这 3 张不同大小的图像分别参与了 3 个子阶段的处理过程。从最小尺寸的图像开始，图像 $\boldsymbol{I}_1$ 通过一个 3×3 的卷积层将通道从 3 扩展为 C'，本文将 C' 设为 64，然后将其传入第一级 Transformer 模块中进行特征提取。特征提取结束后通过 pixel-unshuffle[34] 下采样将图像尺寸缩小一半，但将通道数量翻倍并传入下一级的 Transformer 模块进行特征提取。经过 2 次下采样后输入图像的尺寸缩小为原来的 1/4 但通道数扩展为原来的 4 倍，经过底层的 Transformer 模块后开始通过 pixel-shuffle[34] 进行上采样，逐步恢复至子阶段输入图像大小并通过 1×1 的卷积层调整通道数。最后，通过 1×1 的卷积层将学习到的残差图通道数恢复至 3，并与子阶段输入图像相加得到子阶段的恢复图像 $\boldsymbol{R}_i$。子阶段的恢复结果将参与下一阶段的处理。如图 1 所示，第一阶段的恢复结果 $\boldsymbol{R}_1$ 通过上采样将图像尺寸扩大一倍，并与第二阶段输入的退化图像一起通过一个 3×3 的卷积层将通道数扩展至 64，将这 2 个图像在通道维度进行拼接并通过 1×1 卷积层进行通道缩减以适应模块的输入，并进行下一阶段的图像恢复。整个网络由 3 个处理不同尺度图像的子阶段构成，并通过 3 个阶段的层层递进处理获得最终的图像恢复结果 $\boldsymbol{R}$。

在图像的上采样和下采样过程中，为了保留更多的有效信息，增强模型的恢复能力，本文引入跳跃连接[29]。将下采样过程中编码器的输出与相对应级别的解码器的输入在通道维度上进行拼接，拼接后的结果通过一个 1×1 卷积层调整通道后继续进行上采样操作。为了进一步增强信息的传递，减少多次上采样与下采样过程中带来的信息损失，在 3 个子阶段间同样引入跳跃连接。在 t_{i-1} 阶段的解码器上采样的过程中，将恢复过程中的潜在图像通过上采样扩大图像尺寸后与 t_i 阶段相同级别编码器的输入在通道维度进行拼接，经过一个 1×1 卷积

计算机工程 www.ecice06.com

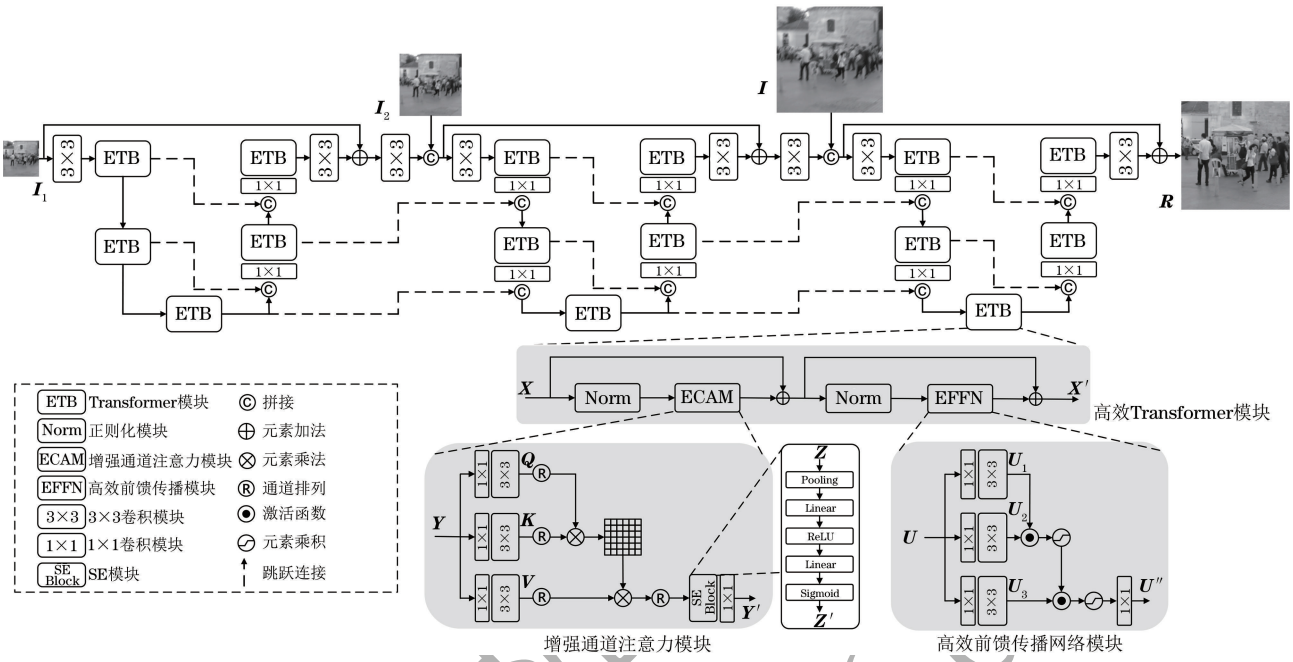


图 4 多阶段去模糊网络结构

Fig. 4 Multi-stage deblurring network structure

层调整通道后作为 t_i 阶段编码器的输入。通过同一阶段内和不同阶段间的跳跃连接，使得整个模型可以更好地利用输入数据的不同特征，从而提高模型的恢复能力。

2.3 高效 Transformer 模块

Transformer 模型相较于 CNN 模型具有更大的感受野，因此与传统的 CNN 模型相比，Transformer 能够有效地提取图像中全局和局部特征之间的联系，从而产生更准确的输出结果[35]。虽然 Transformer 模型具有更强的全局能力，但是由于注意力机制需要处理所有输入位置之间的交互，因此它的计算复杂度会随着输入图像的增大而显著提高，这使得模型的训练和推理过程中成本变得非常高昂，并对模型的规模和性能造成了一定的限制。为了降低注意力机制带来的计算负担，研究者们提出了各种优化和改进方法，如局部注意力[17,36]、分散注意力[37]等技术，以减少模型的计算和内存开销，从而在保持模型性能的同时提高效率。为了解决注意力机制计算复杂度过高的问题，本文提出了一种增强通道注意力模块，并且为了更好地传输通过注意力捕捉到的信息，提出了一种多分支结构的高效前馈传播网络。

2.3.1 增强通道注意力模块

注意力层是 Transformer 结构的核心组成部分，它在输入序列中寻找相关信息以交互和整合不同位置的信息。虽然注意力机制能够处理长距离的依赖关系，但是它的计算复杂度相对较高。受文献[18]工作的启发，本文采用通道注意力来生成图像通道的全局注意力图，通过深度可分离卷积来获取图像的空间信息并缩减参数以提高模型效率，除此之外，为了增强模型的通道表达能力，引入 SE 模块[31]。图 4 详细展示了本文提出的增强通道注意力模块结构。

对于经过归一化处理的张量 $\boldsymbol{Y}\in\mathbb{R}^{H'\times W'\times C'}$，首先将其输入 1×1 的逐点卷积层，把通道数扩展为初始的 3 倍，然后通过 3×3 的逐深度卷积，编码生成关于每个通道的局部空间信息，以增强模型的局部细节提取能力，并生成 $\boldsymbol{Q}=W_d^qW_p^q\boldsymbol{Y}$、$\boldsymbol{K}=W_d^kW_p^k\boldsymbol{Y}$ 和 $\boldsymbol{V}=W_d^vW_p^v\boldsymbol{Y}$ 等 3 个投影，其中，W_p 和 W_d 分别表示 1×1 逐点卷积和 3×3 深度卷积。然后，对生成的查询投影 $\boldsymbol{Q}$、键投影 $\boldsymbol{K}$ 和值投影 $\boldsymbol{V}$ 进行维度重塑，查询投影与键投影进行点积运算来生成大小为 $C'\times C'$ 的注意力矩阵 $\boldsymbol{A}$，而不是在常规空间注意力中生成大小为 $H'W'\times H'W'$ 的注意力矩阵。注意力矩阵 $\boldsymbol{A}$ 经过 Softmax 归一化后与值投影相乘生成关于输入张量 $\boldsymbol{Y}$ 的注意力矩阵 $\boldsymbol{A}'$，将维度重塑回原始维度后将其传入 SE 模块，进一步增强特征的提取能力。

如图 4 所示，注意力矩阵经过重塑维度后直接输入 SE 模块中。SE 模块总体上由压缩和激励 2 个步骤组成。在压缩步骤中，SE 模块先使用全局平均池化来对输入的每个通道进行降维，将大小为 $H'\times W'\times C'$ 的注意力图压缩为 $1\times 1\times C'$ 大小的向量。在激励步骤中，SE 模块使用感知机模块（包

计算机工程 www.ecice06.com

括 2 个线性层和 ReLU 激活函数)对压缩步骤中得到的向量进行激活并使用 Sigmoid 进行归一化,将更新后的特征图经过 1×1 的卷积层后作为输出。综上,整个增强通道注意力模块定义如下:

$$\begin{cases}\boldsymbol{Y}'=W_p\cdot\mathrm{Attention}(\boldsymbol{Q}',\boldsymbol{K}',\boldsymbol{V}')\cdot\mathrm{SE}\\ \mathrm{Attention}(\boldsymbol{Q}',\boldsymbol{K}',\boldsymbol{V}')=\mathrm{Softmax}(\boldsymbol{Q}'\boldsymbol{K}'^{\mathrm{T}}/\alpha)\cdot\boldsymbol{V}'\\ \mathrm{SE}=\sigma_{\mathrm{s}}(\mathrm{FC}(\sigma_{\mathrm{r}}(\mathrm{FC}(\mathrm{AvgPool}(\boldsymbol{A}')))))\end{cases}\tag{4}$$

式中:Attention 表示注意力运算;SE 表示 SE 模块操作;Softmax 表示归一化函数;FC 表示全连接层;AvgPool 表示全局平均池化;W_p 表示深度可分离卷积;σ_{r} 表示 ReLU 激活函数;σ_{s} 表示 Sigmoid 激活函数。

2.3.2 高效前馈传播网络

为了在模块中更好地获取和传输特征,与传统的单分支前馈传播网络模块不同,本文设计了一个带有门控机制的多分支结构的高效前馈传播网络。如图 4 所示,对于输入张量 $\boldsymbol{U}\in\mathbb{R}^{H'\times W'\times C'}$,首先经过 1×1 的卷积层将输入特征进行投影,在通道维度进行线性变换,将通道数扩展为原来的 3 倍,然后通过 3×3 分组深度卷积来学习局部的空间信息并将输入的张量分为 $\boldsymbol{U}_1$、$\boldsymbol{U}_2$ 和 $\boldsymbol{U}_3$ 等 3 个部分。模块在整体结构上采用了三分支结构的设计,通过深度卷积的张量 $\boldsymbol{U}_1$ 与 $\boldsymbol{U}_2$ 进行元素乘积后,采用 Gelu 激活函数引入非线性并增强模型的泛化能力,然后与 $\boldsymbol{U}_3$ 进行元素乘积后再次使用 Gelu 函数进行非线性激活。最后,通过 1×1 的卷积层将通道数缩减至 3 后输出结果。本文提出的高效前馈传播网络通过增加横向的连接,使得信息在网络中可以沿多个路径进行流动。相比单分支结构,在多分支结构下,模块的计算能力更为强大,可以更有效地对数据进行处理和学习,在整体上增强模型的恢复性能。前馈传播网络的模块定义如下:

$$\begin{cases}\boldsymbol{U}'=\sigma_{\mathrm{Gelu}}(W_d^1W_p^1(\boldsymbol{U})\odot W_d^2W_p^2(\boldsymbol{U}))\\ \boldsymbol{U}''=\sigma_{\mathrm{Gelu}}(\boldsymbol{U}'\odot W_d^3W_p^3(\boldsymbol{U}))\end{cases}\tag{5}$$

式中:σ_{Gelu} 表示 Gelu 激活函数;⊙表示元素乘积。

2.4 损失函数

L1 Loss 作为图像恢复领域最常见的损失函数,已经在许多研究[18,38]中被证明是有效的。然而,单一的损失函数无法充分考虑图像的其他因素,例如亮度和对比度,只能优化某些特定的指标,可能会导致恢复的图像存在某些不足。为了更好地优化模型的细节和整体恢复效果,本文在 L1 Loss 损失函数的基础上加入了 SSIM Loss,构成了混合损失函数。SSIM Loss 是一种结构相似度损失函数,通过比较生成图像和真实图像的结构相似度来衡量它们之间的差异。因此,本文混合损失函数的数学表达式如下所示:

$$\begin{cases}L_{\mathrm{L1}}=\dfrac{1}{n}\displaystyle\sum_{i=1}^{n}|x_i-y_i|\\ L_{\mathrm{SSIM}}=\dfrac{1}{n}\displaystyle\sum_{i=1}^{n}[1-\mathrm{SSIM}(x_i,y_i)]\\ L_{\mathrm{Total}}=\lambda L_{\mathrm{L1}}+(1-\lambda)L_{\mathrm{SSIM}}\end{cases}\tag{6}$$

式中:x 和 y 分别表示恢复图像与真实图像;SSIM 表示结构相似度;λ 用于控制 2 个损失函数的比例,本文设置为 0.7。

3 实验结果及分析

3.1 数据集

为了验证多阶段去模糊网络在模糊图像恢复方面的效果,本文选择 GoPro[11]数据集进行实验。作为通过高速相机捕捉到的合成数据集,GoPro 被广泛应用于去模糊模型的训练与测试任务。GoPro 数据集包含 3 214 对模糊和清晰图像,其中 2 103 对用于训练,其余 1 111 对用于测试。考虑到训练的硬件条件与时间成本,将单张 1 280×720 大小的图像以每次重叠 256 像素的方式划分为 8 张 512×512 大小的图片,并将裁切后的图片数量进行精简,得到一共 8 412 对 512×512 大小的图片作为模型的训练集。将 GoPro 中 1 111 对图片以同样的方式裁剪至 512×512 大小作为模型的测试集。为了更好地评估本文提出的模型效果,在 GoPro 训练集上训练多阶段去模糊网络,并直接在 GoPro 测试集和包含 2 025 幅图像的 HIDE[39]数据集上对其进行评估。为了丰富训练数据并提高模型的鲁棒性,在训练过程中对数据集进行水平和垂直翻转。

3.2 实验参数设置

本文采用分布式训练的方式来训练模型,其中采用了 4 张 NVIDIA RTX A5000 GPU,单块显存为 24 GB,CPU 为 AMD EPYC 7551P,内存为 32 GB,操作系统为 Ubuntu 20.04,使用 1.13.1 版本的 PyTorch 深度学习框架来进行训练和测试。本文采用 AdamW 优化器,其中一阶矩和二阶矩的指数衰减率分别设置为 $\beta_1=0.9$、$\beta_2=0.999$,并进行 400 000 次迭代,约 2 400 个训练周期。将初始学习率设置为 3×10^{-4},通过余弦退火法[40]逐渐降低到 5×10^{-5}。多尺度模型在单个子模块上采用了 3 层的编码器-解码器结构,考虑到图像恢复

计算机工程 www.ccice06.com

的效果与效率，在第 1～第 3 层将 Transformer 模块的数量分别设置为[2,4,8]，其中增强通道注意力模块中注意力头数设置为[2,4,8]，并且 3 个子模块的模块数相同。

3.3 评价指标

本文使用了目前图像恢复领域中最常用的 2 个评价指标，即峰值信噪比(PSNR)和结构相似性指标(SSIM)。其中，PSNR 是一种用于衡量恢复图像与原始图像之间差异的评价指标，而 SSIM 则是一种综合考虑亮度、对比度、结构等因素的评价指标，其数值范围在－1～1 之间。结合 PSNR 和 SSIM 这 2 个指标可以更全面地评价图像恢复模型的性能。PSNR 的计算公式如下所示：

$$\begin{cases} R_{\mathrm{PSNR}}=10\lg\left(\dfrac{(2^n-1)^2}{M_{\mathrm{MSE}}}\right) \\ M_{\mathrm{MSE}}=\dfrac{1}{H\cdot M}\sum\limits_{i=1}^{H}\sum\limits_{j=1}^{W}(X(i,j)-Y(i,j))^2 \end{cases} \tag{7}$$

式中：$X(i,j)$ 表示原始图像中像素 (i,j) 的灰度值；$Y(i,j)$ 表示被评估图像中相同位置的像素的灰度值。

相较于 PSNR 指标，SSIM 指标更注重描述图像在亮度、对比度、结构等方面与人眼感知相关的视觉特性，其公式如下所示：

$$R_{\mathrm{SSIM}}=\frac{(2\mu_x\mu_y+C_1)(2\sigma_{xy}+C_2)}{(\mu_x^2+\mu_y^2+C_1)(\sigma_x^2+\sigma_y^2+C_2)} \tag{8}$$

式中：x 和 y 分别表示恢复图像与真实图像；μ_x 和 μ_y 分别是图像 x 和 y 的均值；σ_x^2 和 σ_y^2 分别表示 x 和 y 的方差；σ_{xy} 表示 x 和 y 的协方差；C_1 和 C_2 是 2 个常数。

结合使用 PSNR 和 SSIM 这 2 个指标，能够有效提高图像质量评估的准确性，更全面、更客观地反映模型的图像恢复性能。

3.4 结果分析

将多阶段去模糊网络在 GoPro 和 HIDE 数据集上进行训练测试，并与多个优秀的去模糊网络进行对比，包括 DeepDeblur[11]、DeblurGAN-V2[41]、SRN[23]、PSS-NSC[30]、DMPHN[9]、MT-RNN[42]、MSCAN[43]、MIMO-UNet[24]、SPAIR[44]、IDC[45] 和 T-MIMO-UNet[46]。DeblurGAN-V2 是基于生成对抗网络的图像去模糊方法；SRN 基于尺度递归结构完成去模糊；MT-RNN 基于多时项递归网络完成去模糊；SPAIR 利用失真定位信息进行图像修复；DeepDeblur、PSS-NSC、MSCAN、MIMO-UNet、DMPHN、IDC 和 T-MIMO-UNet 基于多尺度结构进行图像修复。

表 1 展示了上述模型在 GoPro 和 HIDE 数据集中的 PSNR 和 SSIM 指标，最优结果加粗标注。从表中可以看出：本文模型在 GoPro 数据集中取得了最佳的 PSNR 指标，与其余模型相比，PSNR 指标平均提升 1.47 dB；本文模型的 SSIM 指标仅次于 T-MIMO-UNet 模型，比 T-MIMO-UNet 的 SSIM 低 0.011，但相对其他模型平均提高 0.02。本文模型仅在 GoPro 数据集上进行了训练，并在 HIDE 数据集上进行了测试。从表 1 可以看出，本文提出的模型在 PSNR 和 SSIM 指标上优于大部分模型。

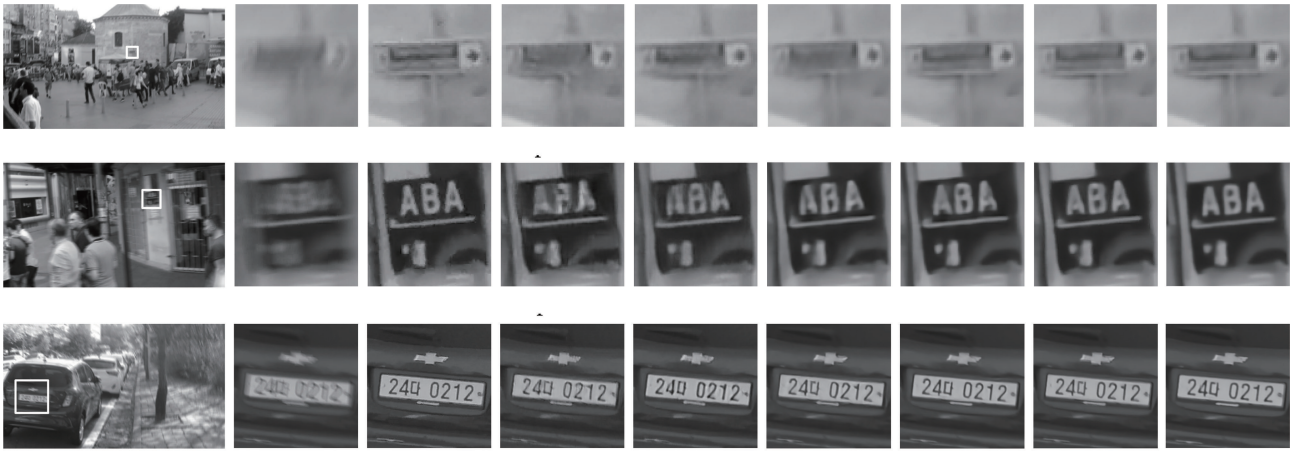
表 1 不同模型的实验结果对比

Table 1 Comparison of experimental results of different models

模型	GoPro		HIDE	
	PSNR/dB	SSIM	PSNR/dB	SSIM
DeepDeblur[11]	29.08	0.914	25.73	0.874
DeblurGAN-V2[41]	29.55	0.934	26.61	0.875
SRN[23]	30.26	0.934	28.36	0.915
PSS-NSC[30]	30.92	0.942	29.11	0.913
IDC[45]	31.11	0.948	—	—
DMPHN[9]	31.20	0.945	29.09	0.924
MSCAN[43]	31.23	0.945	29.63	0.920
MIMO-UNet[24]	31.73	0.951	29.28	0.921
SPAIR[44]	32.06	0.953	**30.92**	**0.931**
T-MIMO-UNet[46]	32.12	**0.966**	—	—
本文模型	**32.23**	0.955	30.12	0.929

为了验证模型的实际效果，本文选择 DeepDeblur[11]、DeblurGAN-V2[41]、DMPHN[9]、MSCAN[43] 和 MIMO-UNet[24] 模型，在 GoPro 数据集中的 3 个不同场景下进行实际去模糊测试。为了更好地体现不同模型之间的差异，本文将去模糊后的图片进行放大处理，便于观测结果。图 5 展示了上述模型分别在 3 个不同场景下的去模糊结果。从图中可以看出，本文模型在 3 个场景下都能产生最清晰锐利的去模糊结果。早期的模型(如 DeepDeblur 和 DeblurGAN-V2)都会产生难以抑制的振铃伪影，影响去模糊结果，而 DMPHN 和 MSCAN 对于细节部分的恢复效果还有待提高。MIMO-UNet 与本文模型结果较为接近，但是在细节部分(如第 3 行的车标)本文模型恢复效果更好。

计算机工程 www.ecice06.com



(a)场景 (b)模糊图像 (c)原图 (d)DeepDeblur (e)DeblurGan-V2 (f)DMPHN (g)MSCAN (h)MIMO-UNet (i)本文模型

图 5 不同模型的去模糊结果对比

Fig. 5 Comparison of deblurring results of different models

3.5 消融实验

3.5.1 增强通道注意力模块消融实验

为了验证增强通道注意力中 SE 模块以及子模块间连接(EC)的有效性,本文设置了消融实验。将多阶段 Transformer 去模糊网络中增强通道注意力的 SE 模块和阶段间跳跃连接移除,构成基准模型并在基准模型的基础上依次添加模块来验证其有效性。本文使用 PSNR 和 SSIM 指标来量化各模块带来的性能提升,从表 2 可以看出,在基准模型的基础上,添加 SE 模块和阶段间跳跃连接使得 PSNR/SSIM 指标分别提升 0.1 dB/0.001 和 0.213 dB/0.002,而 2 个模块的组合带来了巨大的性能提升,相比基准模型在 PSNR、SSIM 指标上分别提升了 1.12 dB、0.012。

表 2 增强通道注意力模块消融实验

Table 2 Enhanced channel attention module ablation experiment

模型	SE	EC	PSNR/dB	SSIM
Base			31.112	0.943
Base+SE	✓		31.212	0.944
Base+EC		✓	31.325	0.945
Base+SE+EC	✓	✓	32.232	0.955

3.5.2 高效前馈传播网络消融实验

为了证明高效前馈传播网络的有效性,同样进行了消融实验。在多尺度 Transformer 去模糊网络的基础上,把 Transformer 模块中的多分支前馈传播网络设置为单分支结构,由一层 3×3 的卷积层和两层 1×1 的卷积层组成,将其设置为基准前馈传播网络。实验结果如表 3 所示,从中可以看出,在基准前馈传播模块的基础上加入多分支结构,能够带来巨大的性能提升,PSNR 和 SSIM 相比基准前馈传播模块分别提升了 2.017 dB 和 0.024,证明了多分支结构前馈传播网络的有效性。

表 3 高效前馈传播网络消融实验

Table 3 Efficient feedforward propagation network ablation experiment

模型	EFFN	PSNR/dB	SSIM
Base		30.215	0.931
Base+EFFN	✓	32.232	0.955

4 结束语

针对 CNN 结构感受野较小以及多次上采样与下采样过程中信息丢失的问题,本文提出一种基于 Transformer 的多阶段去运动模糊网络。首先,网络采用 3 个处理不同尺度图像的编码器-解码器结构,并且在单个结构内以及结构间通过跳跃连接来尽可能减少多次上采样与下采样过程中带来的信息损失;其次,本文提出一个 Transformer 模块,得益于增强通道注意力模块和高效前馈传播模块,使得高效 Transformer 模块能够在保持全局注意力的同时获取较高的效率。通过大量实验进行验证,结果表明本文所提模型具有有效性。但是,本文提出的去模糊方法仍存在不足,基于多阶段的网络在处理速度上还有一定的改进空间,今后将围绕模型轻量化以及优化处理速度这两个方面展开研究。

参考文献

[1] KALMAN R E. A new approach to linear filtering and prediction problems[J]. Journal of Basic Engineering, 1960, 82(1): 35-45.

[2] LUCY L B. An iterative technique for the rectification of observed distributions[J]. The Astronomical Journal, 1974, 79: 745.

[3] RICHARDSON W H. Bayesian-based iterative method of

计算机工程 www.ecice06.com

image restoration[J]. Journal of the Optical Society of America, 1972, 62(1): 55.
[4] KRISHNAN D, FERGUS R. Fast image deconvolution using hyper-Laplacian priors[EB/OL]. [2023-07-05]. https://proceedings.neurips.cc/paper/2009/file/3dd48ab31d016ffcbf3314df2b3cb9ce-Paper.pdf.
[5] HRADIŠ M, KOTERA J, ZEMČÍK P, et al. Convolutional neural networks for direct text deblurring[EB/OL]. [2023-07-05]. https://www.semanticscholar.org/paper/Convolutional-Neural-Networks-for-Direct-Text-Hradi%C5%A1-Kotera/423584105e5f6adc5981c87f2af8fc5ff2bb9064.
[6] SCHULER C J, HIRSCH M, HARMELING S, et al. Learning to deblur[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(7): 1439-1451.
[7] XU X, PAN J, ZHANG Y J, et al. Motion blur kernel estimation via deep learning[J]. IEEE Transactions on Image Processing, 2018, 27(1): 194-205.
[8] KUPYN O, BUDZAN V, MYKHAILYCH M, et al. DeblurGAN: blind motion deblurring using conditional adversarial networks[C]// Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2018: 8183-8192.
[9] ZHANG H G, DAI Y C, LI H D, et al. Deep stacked hierarchical multi-patch network for image deblurring[C]// Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2019: 5971-5979.
[10] PUROHIT K, RAJAGOPALAN A N. Motion deblurring with an adaptive network[EB/OL]. [2023-07-05]. http://arxiv.org/abs/1903.11394v4.
[11] NAH S, KIM T H, LEE K M. Deep multi-scale convolutional neural network for dynamic scene deblurring[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2017: 257-265.
[12] DONG J X, PAN J S, YANG Z B, et al. Multi-scale residual low-pass filter network for image deblurring[C]//Proceedings of IEEE/CVF International Conference on Computer Vision. Washington D.C., USA: IEEE Press, 2023: 12345-12354.
[13] LIU P J, ZHANG H Z, ZHANG K, et al. Multi-level wavelet-CNN for image restoration[EB/OL]. [2023-07-05]. https://arxiv.org/pdf/1805.07071.
[14] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16 × 16 words: Transformers for image recognition at scale[EB/OL]. [2023-07-05]. https://arxiv.org/abs/2010.11929.
[15] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[EB/OL]. [2023-07-05]. https://arxiv.org/abs/1706.03762.
[16] WANG Z D, CUN X D, BAO J M, et al. Uformer: a general U-shaped Transformer for image restoration[C]//Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2022: 17662-17672.
[17] LIU Z, LIN Y T, CAO Y, et al. Swin Transformer: hierarchical vision Transformer using shifted windows[C]// Proceedings of IEEE/CVF International Conference on Computer Vision. Washington D.C., USA: IEEE Press, 2021: 9992-10002.
[18] ZAMIR S W, ARORA A, KHAN S, et al. Restormer: efficient Transformer for high-resolution image restoration[C]// Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2022: 5718-5729.
[19] ZHAO Q, YANG H, ZHOU D M, et al. Rethinking image deblurring via CNN-Transformer multiscale hybrid architecture[J]. IEEE Transactions on Instrumentation Measurement, 2023, 72: 3230482.
[20] KONG L S, DONG J X, GE J J, et al. Efficient frequency domain-based transformers for high-quality image deblurring[C]// Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2023: 5886-5895.
[21] CUI Y N, TAO Y, REN W Q, et al. Dual-domain attention for image deblurring[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 37(1): 479-487.
[22] KIM J, LEE J K, LEE K M. Accurate image super-resolution using very deep convolutional networks[C]// Proceedings of IEEE Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2016: 1646-1654.
[23] TAO X, GAO H Y, SHEN X Y, et al. Scale-recurrent network for deep image deblurring[C]//Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2018: 8174-8182.
[24] CHO S J, JI S W, HONG J P, et al. Rethinking coarse-to-fine approach in single image deblurring[C]//Proceedings of IEEE/CVF International Conference on Computer Vision. Washington D.C., USA: IEEE Press, 2021: 4621-4630.
[25] 王向军,欧阳文森. 多尺度循环注意力网络运动模糊图像复原方法[J]. 红外与激光工程, 2022, 51(6): 460-468.
WANG X J, OUYANG W S. Multi-scale recurrent attention network for image motion deblurring[J]. Infrared and Laser Engineering, 2022, 51(6): 460-468. (in Chinese)
[26] ZHANG Y, LI Q, QI M, et al. Multi-scale frequency separation network for image deblurring[EB/OL]. [2023-07-05]. https://arxiv.org/abs/2206.00798.
[27] WOO S, PARK J, LEE J Y, et al. CBAM: convolutional block attention module[EB/OL]. [2023-07-05]. https://arxiv.org/abs/1807.06521.
[28] HASSANI A, WALTON S, LI J C, et al. Neighborhood attention Transformer[C]// Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2023: 6185-6194.
[29] RONNEBERGER O, FISCHER P, BROX T. U-Net: convolutional networks for biomedical image segmentation[EB/OL]. [2023-07-05]. https://arxiv.org/abs/1505.04597.
[30] GAO H Y, TAO X, SHEN X Y, et al. Dynamic scene deblurring with parameter selective sharing and nested skip connections[C]// Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2019: 3843-3851.
[31] HU J, SHEN L, SUN G. Squeeze-and-Excitation networks[C]// Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2018: 7132-7141.
[32] SZEGEDY C, VANHOUCKE V, IOFFE S, et al. Rethinking the inception architecture for computer vision[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2016: 2818-2826.
[33] TSAI F J, PENG Y T, LIN Y Y, et al. Stripformer: strip Transformer for fast image deblurring[EB/OL]. [2023-07-05]. https://arxiv.org/abs/2204.04627.
[34] SHI W Z, CABALLERO J, HUSZAR F, et al. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2016: 1874-1883.
[35] 赵敬伟,林珊玲, 梅婷, 等. 基于 YOLACT 与 Transformer 相结合的实例分割算法研究[J]. 半导体光电, 2023, 44(1): 134-140.
ZHAO J W, LIN S L, MEI T, et al. Research on instance segmentation algorithm based on YOLACT and Transformer[J].

计算机工程 www.ecice.com

Semiconductor Optoelectronics, 2023, 44(1): 134-140. (in Chinese)
[36] CHEN C F, PANDA R, FAN Q F. RegionViT: regional-to-local attention for Vision Transformers[EB/OL]. [2023-07-05]. http://arxiv.org/abs/2106.02689v3.
[37] ZHANG H, WU C R, ZHANG Z Y, et al. ResNeSt: split-attention networks [C]// Proceedings of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Washington D.C., USA: IEEE Press, 2022: 2735-2745.
[38] LIANG J Y, CAO J Z, SUN G L, et al. SwinIR: image restoration using Swin Transformer [C]// Proceedings of IEEE/CVF International Conference on Computer Vision. Washington D.C., USA: IEEE Press, 2021: 1833-1844.
[39] SHEN Z Y, WANG W G, LU X K, et al. Human-aware motion deblurring [C]// Proceedings of IEEE/CVF International Conference on Computer Vision. Washington D.C., USA: IEEE Press, 2019: 5572-5581.
[40] LOSHCHILOV I, HUTTER F. SGDR: stochastic gradient descent with warm restarts[EB/OL]. [2023-07-05]. http://arxiv.org/abs/1608.03983v5.
[41] KUPYN O, MARTYNIUK T, WU J R, et al. DeblurGAN-V2: deblurring (orders-of-magnitude) faster and better[C]// Proceedings of IEEE/CVF International Conference on Computer Vision. Washington D.C., USA: IEEE Press, 2019: 8877-8886.
[42] PARK D, KANG D U, KIM J, et al. Multi-temporal recurrent neural networks for progressive non-uniform single image deblurring with incremental temporal training[EB/OL]. [2023-07-05]. https://arxiv.org/abs/1911.07410.
[43] WAN S D, TANG S, XIE X Z, et al. Deep convolutional-neural-network-based channel attention for single image dynamic scene blind deblurring[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 31(8): 2994-3009.
[44] PUROHIT K, SUIN M, RAJAGOPALAN A N, et al. Spatially-adaptive image restoration using distortion-guided networks [C]// Proceedings of IEEE/CVF International Conference on Computer Vision. Washington D.C., USA: IEEE Press, 2021: 2289-2299.
[45] WANG J B, WANG Z Q, YANG A P. Iterative dual CNNs for image deblurring[J]. Mathematics, 2022, 10(20): 3891.
[46] 李现国,李滨. 基于 Transformer 和多尺度 CNN 的图像去模糊[J]. 计算机工程, 2023, 49(9): 226-233, 245.
LI X G, LI B. Image deblurring based on Transformer and multi-scale CNN[J]. Computer Engineering, 2023, 49(9): 226-233, 245. (in Chinese)

编辑 吴云芳

计算机工程 www.ecice06.com